

Module : Business Intelligence et Entrepôts de Données Avancés

Liste des projets

Projet 1 : Tableau de bord temps réel des ventes avec Change Data Capture (CDC)

Contexte : Une entreprise de e-commerce souhaite surveiller ses ventes en temps réel à partir de sa base de données transactionnelle (PostgreSQL/MySQL).

Objectifs : Mettre en place Debezium pour capturer les changements, streamer via Kafka, transformer avec Kafka Streams ou Flink, charger dans une base analytique (ClickHouse ou Druid) et visualiser avec Superset ou Power BI.

Technologies : Debezium, Kafka, Apache Flink, ClickHouse, Superset, Docker, Kubernetes.

Aspects avancés : Gestion des erreurs, exactly-once semantics, scaling horizontal, monitoring avec Prometheus/Grafana.

Projet 2 : Maintenance prédictive pour IoT industriel avec Data Warehouse temporel

Contexte : Une usine équipée de capteurs (température, vibration, pression) veut anticiper les pannes.

Objectifs : Ingérer des flux MQTT, stocker dans un data lake (Hudi ou Iceberg), construire un entrepôt de données temporel avec granularité variable, entraîner un modèle de régression logistique/XGBoost pour prédire les pannes, intégrer les scores dans un tableau de bord.

Technologies : MQTT, Apache Hudi, Spark Structured Streaming, MLflow, Tableau/Power BI.

Aspects avancés : Feature store, détection de concept drift, orchestration Airflow.

Projet 3 : Customer 360 avec graphe et entrepôt de données

Contexte : Une banque veut fusionner les données clients (transactions, interactions call center, web, mobile).

Objectifs : Modéliser un graphe de relations (client, compte, agence, produit), importer dans Neo4j, créer un entrepôt en étoile pour les KPIs classiques (solde moyen, turnover), lier le graphe et l'entrepôt via des vues matérialisées, développer un dashboard interactif filtré par communautés.

Technologies : Neo4j, PostgreSQL (entrepôt), dbt, Looker, Python (NetworkX).

Aspects avancés : Algorithme de détection de communautés (Louvain), recommandation de produits.

Projet 4 : Détection automatique d'anomalies financières avec BI augmentée

Contexte : Une société de paiement doit détecter des fraudes ou erreurs comptables.

Objectifs : Construire un pipeline d'ingestion de transactions (simulation haute fréquence), implémenter des modèles non supervisés (Isolation Forest, Autoencoder) pour

flagger les anomalies, exposer les résultats via une API REST, créer un rapport BI permettant l'investigation manuelle et l'annotation.

Technologies : Python (scikit-learn, PyOD), FastAPI, Snowflake, Streamlit ou Metabase.

Aspects avancés : Feedback loop actif (active learning), explicabilité des anomalies (SHAP).

Projet 5 : Interface BI conversationnelle (Chat avec vos données)

Contexte : Les utilisateurs métier veulent interroger l'entrepôt en langage naturel.

Objectifs : Développer un agent LLM (GPT ou LLaMA fine-tuné) qui traduit des questions françaises en SQL, exécute sur un entrepôt (BigQuery), puis génère des réponses ou des visualisations. Ajouter un cache sémantique et une validation syntaxique.

Technologies : LangChain, Streamlit, BigQuery, Hugging Face, Ollama (modèle local).

Aspects avancés : Gestion des ambiguïtés, historique des conversations, contrôles d'accès par métier.

Projet 6 : Fédération multi-cloud et reporting unifié

Contexte : Une entreprise a des données sur AWS (Redshift), Azure (Synapse) et GCP (BigQuery).

Objectifs : Utiliser Trino (ex-Presto) comme moteur de requêtes fédérées, créer des vues logiques, définir des politiques de data virtualization, construire un tableau de bord unique croisant les sources, optimiser les jointures cross-cloud avec caching.

Technologies : Trino, Starburst, dbt, Tableau, Terraform.

Aspects avancés : Pushdown optimization, chiffrage inter-cloud, coût par requête.

Projet 7 : Data Lakehouse pour l'analyse logistique (e-commerce)

Contexte : Un détaillant combine des flux batch (commandes) et streaming (tracking colis).

Objectifs : Implémenter un lakehouse avec Apache Iceberg, gérer les upserts et time travel, créer des tables BI avec Spark SQL, modéliser un schéma en constellation, exposer via Trino pour des dashboards temps réel.

Technologies : Apache Iceberg, Spark, MinIO (S3 on-prem), Trino, Superset.

Aspects avancés : Optimisation des fichiers (Z-order, compaction), gestion des partitions évolutives.

Projet 8 : Sécurité dynamique (Row-Level Security) pour un entrepôt santé

Contexte : Un hôpital souhaite partager des indicateurs sans exposer les données patient identifiantes.

Objectifs : Modéliser un entrepôt en étoile (faits consultations, diagnostics), implémenter des politiques de masquage dynamique selon le rôle (médecin, administratif, chercheur), utiliser des vues sécurisées avec des fonctions utilisateur, auditer les accès.

Technologies : PostgreSQL (RLS), Apache Ranger, Superset avec filtres utilisateur, Keycloak.

Aspects avancés : Tokenization à la volée, audit trail dans Elasticsearch.

Projet 9 : Contrôleur de chaîne logistique avec géospatial analytics

Contexte : Un transporteur veut optimiser les tournées et surveiller les retards.

Objectifs : Ingérer des positions GPS (Kafka), enrichir avec données météo, charger dans un entrepôt PostGIS, créer des dashboards avec des cartes interactives (isochrones, heatmaps) et des alertes prédictives de retard via régression spatiale.

Technologies : Kafka, PostGIS, Geoserver, Kepler.gl, Mapbox, Prophet.

Aspects avancés : Indexation spatiale (R-tree), clustering de trajectoires (DBSCAN).

Projet 10 : Analyse de sentiment des réseaux sociaux intégrée à l'entrepôt commercial

Contexte : Une marque veut corréliser les mentions Twitter/Instagram avec les ventes.

Objectifs : Streamer les tweets via Twitter API v2, extraire les sentiments avec un modèle BERT fine-tuné (ou camembert), joindre aux transactions, produire des KPIs (sentiment score vs chiffre d'affaires) dans un dashboard temps différé.

Technologies : Apache NiFi, Spark NLP, Elasticsearch, Kibana, dbt.

Aspects avancés : Analyse d'aspects (aspect-based sentiment), détection de campagnes virales.

Projet 11 : Tableau de bord prédictif de churn avec explainable AI (XAI)

Contexte : Un opérateur télécom veut réduire l'attrition.

Objectifs : Construire un entrepôt contenant les logs d'appels, réclamations, données socio-démographiques, entraîner un modèle LightGBM pour prédire le churn à J+30, générer des explications individuelles (LIME, SHAP), intégrer dans un dashboard interactif (filtres par segment, what-if simulation).

Technologies : BigQuery, dbt, Vertex AI (ou SageMaker), Power BI (visualisations personnalisées).

Aspects avancés : Déploiement A/B testing du modèle, monitoring du drift.

Projet 12 : Optimisation des stocks en temps réel avec in-memory BI (Apache Pinot)

Contexte : Un retailer veut ajuster les stocks pendant les soldes.

Objectifs : Ingestions de flux de ventes et niveaux de stock (Kafka), stocker dans Pinot pour des requêtes sub-secondes, développer une API REST pour des recommandations de réapprovisionnement, créer un dashboard réactif (streamlit) qui interroge Pinot.

Technologies : Apache Pinot, Kafka, Debezium, Streamlit, Redis (cache).

Aspects avancés : Star-tree index, requêtes avec agrégations filtrées, tolérance aux pannes.

Projet 13 : Tableau de bord de qualité de données avec profilage et traçabilité

Contexte : Une DSI veut monitorer la santé des données dans l'entrepôt.

Objectifs : Développer un framework de tests Great Expectations, exécuter des contrôles (nulls, unicité, patterns, fraîcheur), générer un score de qualité, tracer la lignée des données (OpenLineage/Marquez), visualiser dans un dashboard temps réel avec alertes.

Technologies : Great Expectations, Airflow, Marquez, Superset, dbt (tests intégrés).

Aspects avancés : Anomalie détection sur les métriques de qualité, auto-réparation simple.

Projet 14 : Preuve de provenance des données (Blockchain) pour rapports audités

Contexte : Un cabinet d'audit doit certifier l'intégrité des rapports financiers.

Objectifs : Hasher les étapes ETL et enregistrer les hashes sur Hyperledger Fabric ou une sidechain Ethereum, créer un mécanisme de vérification de non-répudiation, intégrer un visualiseur de chaîne de blocs dans Power BI.

Technologies : Hyperledger Besu, Web3.py, PostgreSQL, Power BI (API custom).

Aspects avancés : Smart contract pour les droits d'accès, preuve à divulgation nulle.

Projet 15 : BI adaptative – recommandation personnalisée de rapports

Contexte : Un portail BI reçoit des centaines de rapports ; les utilisateurs sont submergés.

Objectifs : Collecter les logs de navigation (clics, temps de visualisation), construire un moteur de recommandation collaborative + content-based, intégrer les recommandations dans l'interface BI (ex : Metabase modifiée), évaluer l'augmentation d'utilisation.

Technologies : Metabase (open source), Python (Surprise, scikit-learn), PostgreSQL, RabbitMQ.

Aspects avancés : Apprentissage par renforcement (bandits contextuels), A/B testing.

Projet 16 : Prédiction de consommation énergétique et détection d'anomalies pour smart grid

Contexte : Un fournisseur d'électricité gère des compteurs intelligents (données 15 min).

Objectifs : Ingérer des séries temporelles (InfluxDB ou TimescaleDB), construire un entrepôt de données avec des granularités (heure, jour), entraîner un modèle LSTM ou Prophet par cluster de foyers, détecter des pics anormaux, dashboard avec cartes de charge.

Technologies : TimescaleDB, Prometheus, TensorFlow, Grafana, Kafka.

Aspects avancés : Fenêtrage temporel adaptatif, incrémental training.

Projet 17 : RH Analytics – Risque d'attrition et simulations « what-if »

Contexte : Une entreprise souhaite réduire le turnover.

Objectifs : Entrepôt RH (données RH, enquêtes, performances), modéliser le risque d'attrition par Random Forest, implémenter une interface de simulation (changer salaire, télétravail, etc.) et visualiser l'impact prédit, dashboard pour les managers.

Technologies : dbt (transformations), MLflow, R Shiny ou Dash, Snowflake.

Aspects avancés : Interprétabilité des contre-factuels (DICE), intégration avec Active Directory.

Projet 18 : Marketing Mix Modeling (MMM) avec attribution multi-touch

Contexte : Un annonceur veut mesurer le ROI de chaque canal (TV, search, social).

Objectifs : Collecter les dépenses média et les ventes, construire un modèle MMM (régression ridge, Bayesian) tenant compte des saturations et interactions, intégrer dans un

dashboard permettant des scénarios budgétaires, comparer avec l'attribution data-driven (Shapley value).

Technologies : PyMC3, Streamlit, BigQuery, Looker (embedded).

Aspects avancés : Réduction de dimension (adstock), incrémentalité via geo experiments.

Projet 19 : Détection de fraude en temps réel avec CEP et dashboard BI

Contexte : Une plateforme de paiement en ligne doit bloquer les transactions suspectes en $<100\text{ms}$.

Objectifs : Implémenter un moteur Complex Event Processing (Esper ou Flink CEP), définir des règles (taux, montant, géographie), enrichir avec données dérivées (agrégats glissants), envoyer les alertes à un dashboard (Kibana) et à un stockage pour analyse rétrospective.

Technologies : Apache Flink (CEP library), Elasticsearch, Kibana, Redis, Kafka.

Aspects avancés : Détection de schémas absents (absence pattern), machine learning hybride (règles + modèle léger).

Modalités d'évaluation des projets

- Soutenance orale de 30 minutes (20 min présentation + 10 min questions).
- Rapport écrit (20-30 pages) : architecture, modélisation, choix techniques, tests, performances.
- Dépôt GitHub avec README, docker-compose (si applicable), et pipeline CI/CD basique.
- Démonstration live du dashboard et de la résilience (panne simulée, reprise).
- Note de projet : 40% réalisation technique, 30% qualité BI/visualisation, 20% originalité/complexité, 10% documentation.